Dari Fitur Anonim ke Peringkat Tersembunyi: Prediksi Skor Kompetisi Berbasis Tabular Foundation Model dan Koreksi Rank Bertingkat dengan Validasi Bebas Kebocoran

Second Choice

1. **Riantama Putra**
2. **Haikal Muhammad Royyan**
3. **Defina Aurellia Ningsih**
4. **Taufiq Muhammad Arif**

DATA SCIENCE COMPETITION

FIK FAIR 2026

UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN" JAKARTA

2026

LEMBAR PERNYATAAN ORISINALITAS
DAN DEKLARASI PENGGUNAAN KECERDASAN BUATAN GENERATIF

Kami yang bertanda tangan di bawah ini:
Nama Tim : Second Choice
Nama Ketua Tim : Riantama Putra
Nama Anggota Tim 1 : Haikal Muhammad Royyan
Nama Anggota Tim 2 : Defina Aurellia Ningsih
Nama Anggota Tim 3 : Taufiq Muhammad Arif

Dengan ini menyatakan bahwa laporan yang kami lampirkan dalam perlombaan Data Science Competition FIK FAIR 2026 merupakan karya orisinal milik tim kami, bebas dari segala bentuk plagiarisme, serta belum pernah diajukan dalam kompetisi manapun.

Kami juga menyatakan telah memanfaatkan kecerdasan buatan generatif (Generative AI) dalam penyusunan laporan ini. Adapun model yang digunakan adalah sebagai berikut:

Nama Model: Claude Opus 5.5

Pengembang Model: Anthropic

Model kecerdasan buatan generatif tersebut kami gunakan untuk keperluan peringkasan informasi serta penyusunan laporan.

Kami menyatakan bahwa seluruh keluaran dari model kecerdasan buatan generatif yang digunakan telah melalui proses tinjauan, verifikasi, dan pengolahan kembali oleh seluruh anggota tim. Segala isi laporan yang diserahkan sepenuhnya merupakan hasil pemahaman, analisis, dan tanggung jawab kami selaku peserta kompetisi.

Apabila di kemudian hari terbukti adanya pelanggaran terhadap pernyataan ini, kami bersedia menerima konsekuensi yang telah ditetapkan oleh panitia FIK FAIR 2026 berupa sanksi diskualifikasi dari perlombaan. Demikian pernyataan ini kami buat dengan sesungguhnya, untuk dapat dipergunakan sebagaimana mestinya.

Bandung, 11 Oktober 2026

Yang menyatakan,



Riantama Putra

ABSTRAK

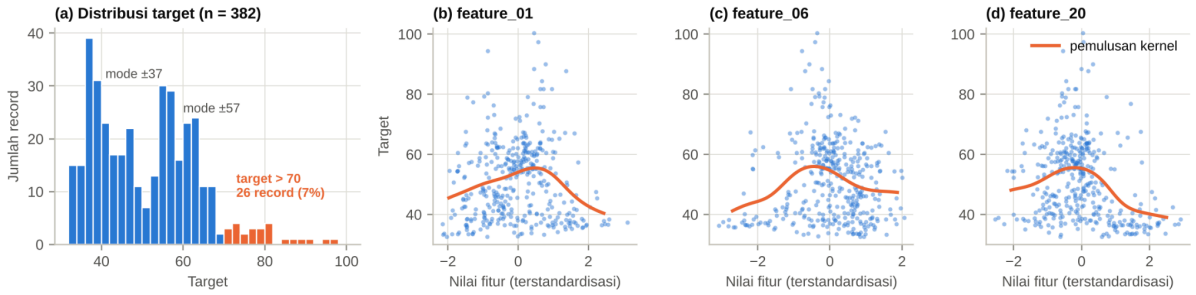
Indeks komposit berbasis indikator lingkungan dan iklim sering dibagikan dalam bentuk tersamarkan agar entitas aslinya tidak dapat dikenali. Data Science Competition FIK FAIR 2026 menantang peserta memprediksi *Anonymous Competition Score* dari 24 fitur anonim hasil proyeksi linear privat, dengan hanya 382 record latih, 96 record uji, dan RMSE sebagai metrik. Tantangannya meliputi sampel yang kecil, fitur yang sangat kolinear, target bimodal berekor berat, serta *public leaderboard* yang hanya berisi 29 record. Penelitian ini mengusulkan pipeline tiga lapis yang dibangun di atas audit forensik data dan validasi silang bersarang 5-fold × 3 *repeat*. EDA menemukan bahwa sinyal target tersimpan pada komponen fitur bervarians kecil, pergeseran latih–uji tergolong ringan (AUC *adversarial validation* 0,55–0,61), dan posisi baris pada berkas data membawa informasi peringkat target (Spearman $\rho = -0{,}981$). Lapisan pertama merata-ratakan dua *tabular foundation model*, TabICL dan TabPFN-3.5, yang diperkuat *pseudo-labeling* transduktif, lalu memadukannya dengan SVR multi-PCA. Lapisan ini mencapai RMSE 7,23, lebih baik daripada GBDT (8,90) dan regresi linear (10,77). Lapisan kedua memetakan prediksi fitur ke kurva target latih berdasarkan posisi relatif yang dinormalisasi per partisi (RMSE 3,61). Lapisan ketiga menerapkan empat koreksi bertingkat, yaitu koreksi *rank* berbasis tetangga fitur, residual Ridge, pemulusan *local-linear*, dan *Kernel Ridge Regression* RBF. Seluruh pemilihan konfigurasi dilakukan di dalam partisi latih. Model final mencapai RMSE validasi silang 3,016 dan membaik pada 15 dari 15 fold. RMSE *public leaderboard*-nya 1,7222, atau 78% lebih rendah daripada model berbasis fitur terbaik. Peringkat lima versi terakhir menurut validasi silang identik dengan peringkatnya menurut skor *public*, dan perbaikan tetap bertahan pada *grouped stress test*. Galat yang tersisa terkonsentrasi pada 10% record bertarget tertinggi, yang menyumbang 34,5% galat kuadrat. Pipeline dilengkapi *manifest* SHA-256, keluaran yang identik saat dijalankan ulang, dan mode cadangan berbasis fitur untuk data tanpa urutan bermakna. Temuan ini menegaskan bahwa audit struktur dataset dan validasi yang bebas kebocoran sama pentingnya dengan pemilihan algoritma.

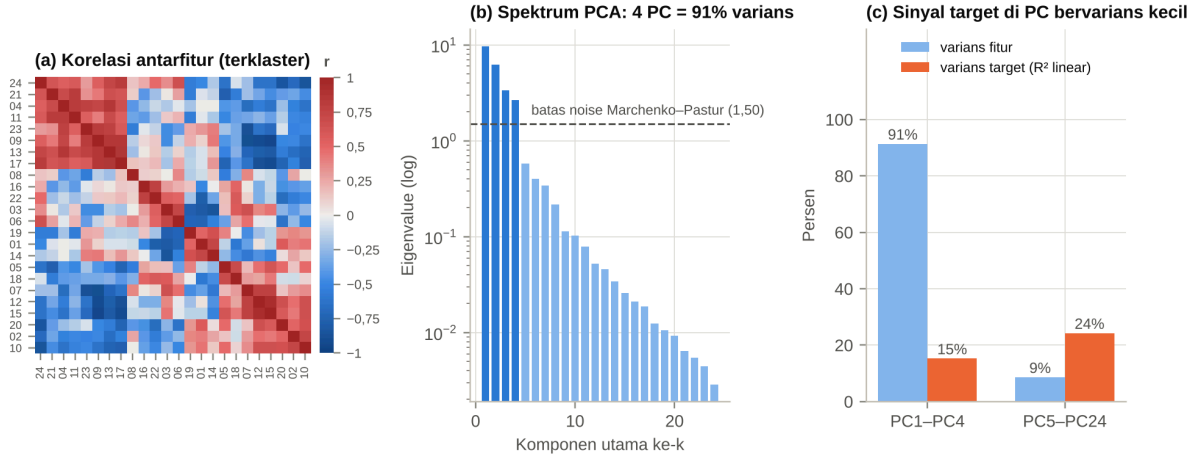
Kata kunci: *tabular foundation model*, *pseudo-labeling*, validasi silang bersarang, audit kebocoran data, regresi data kecil

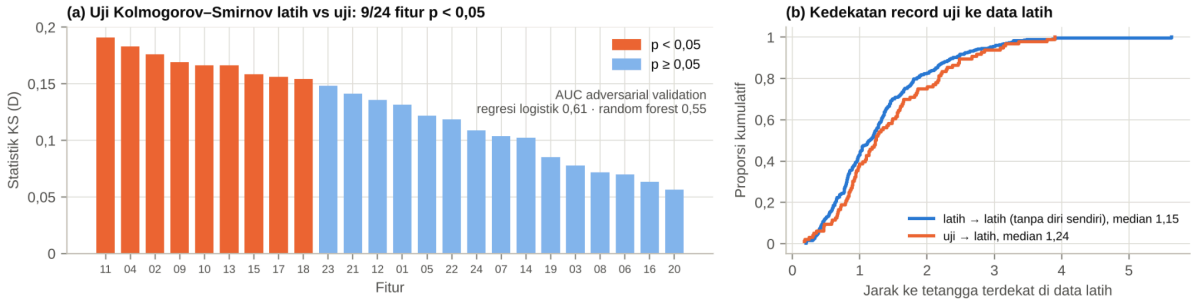
DAFTAR ISI

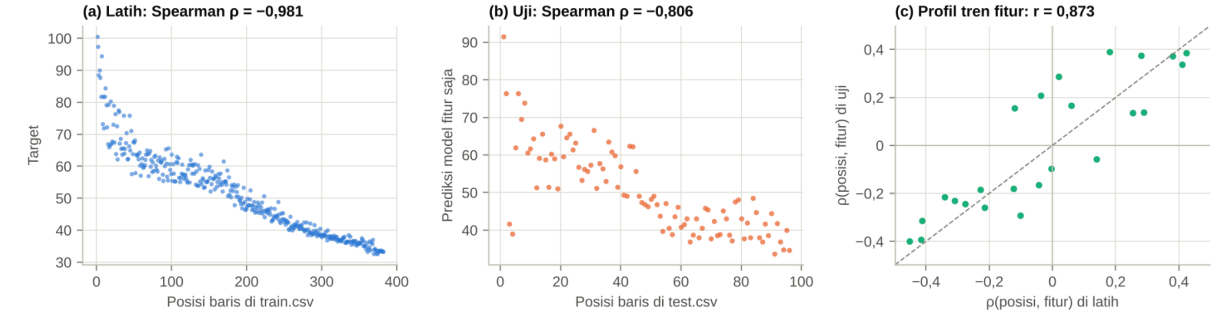
LEMBAR PERNYATAAN ORISINALITAS..... i
ABSTRAK..... iii
DAFTAR ISI..... iv
DAFTAR GAMBAR..... v
BAB I
PENDAHULUAN..... 1
1.1 Latar Belakang..... 1
1.2 Rumusan Masalah..... 2
1.3 Tujuan..... 2
BAB II
PEMBAHASAN..... 3
2.1 Exploratory Data Analysis..... 3
2.1.1 Kualitas dan Pembersihan Data..... 3
2.1.2 Distribusi Target dan Hubungan Non-linear..... 3
2.1.3 Struktur Fitur: Kolinearitas dan Spektrum PCA..... 4
2.1.4 Pergeseran Distribusi Latih–Uji..... 5
2.1.5 Audit Urutan Penyimpanan..... 5
2.2 Machine Learning Deployment..... 7
2.2.1 Protokol Validasi dan Aturan Adopsi..... 7
2.2.2 Lapisan Fitur..... 8
2.2.3 Lapisan Urutan dan Koreksi Bertingkat..... 9
2.2.4 Kesiapan Implementasi dan Reproduktibilitas..... 10
2.3 Hasil Prediksi..... 11
BAB III
PENUTUP..... 14
3.1 Kesimpulan dan Saran..... 14
DAFTAR PUSTAKA..... 4
LAMPIRAN (Opsional)..... 5

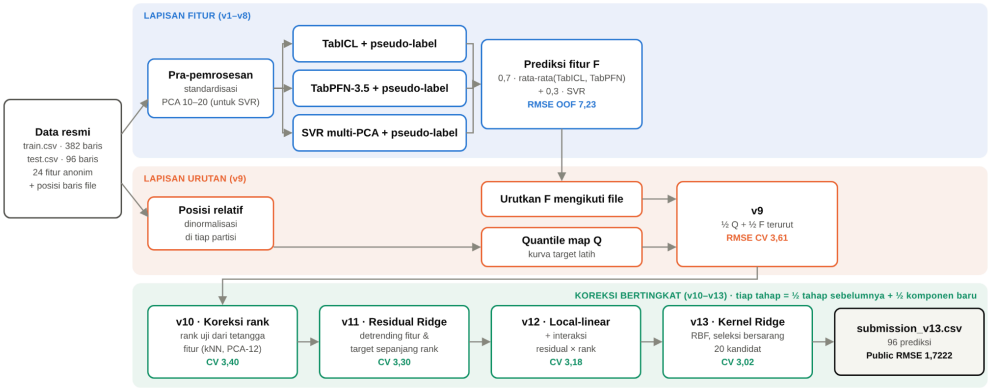
DAFTAR GAMBAR



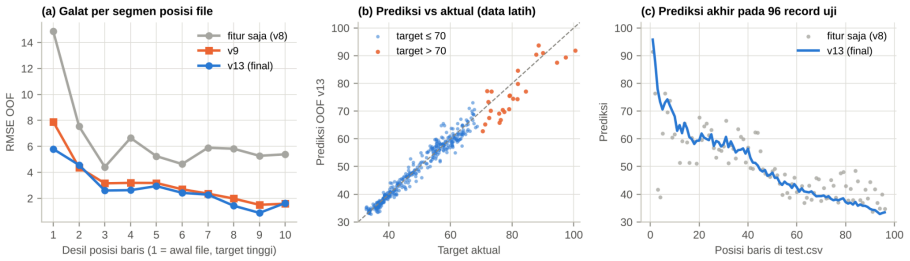


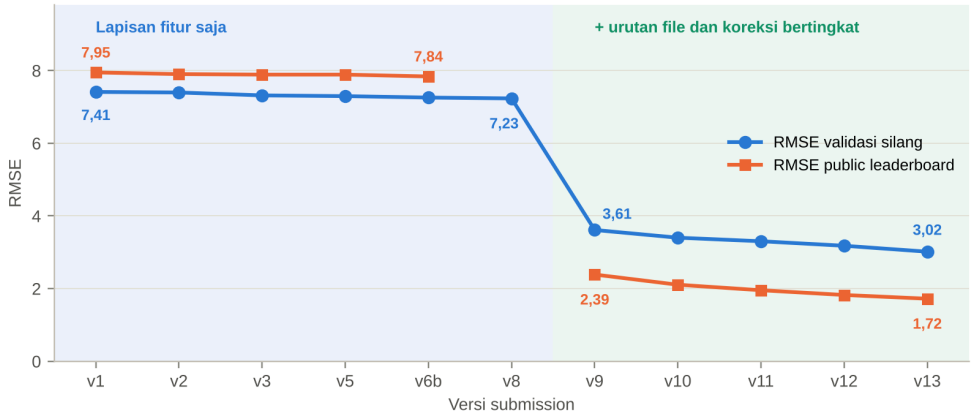


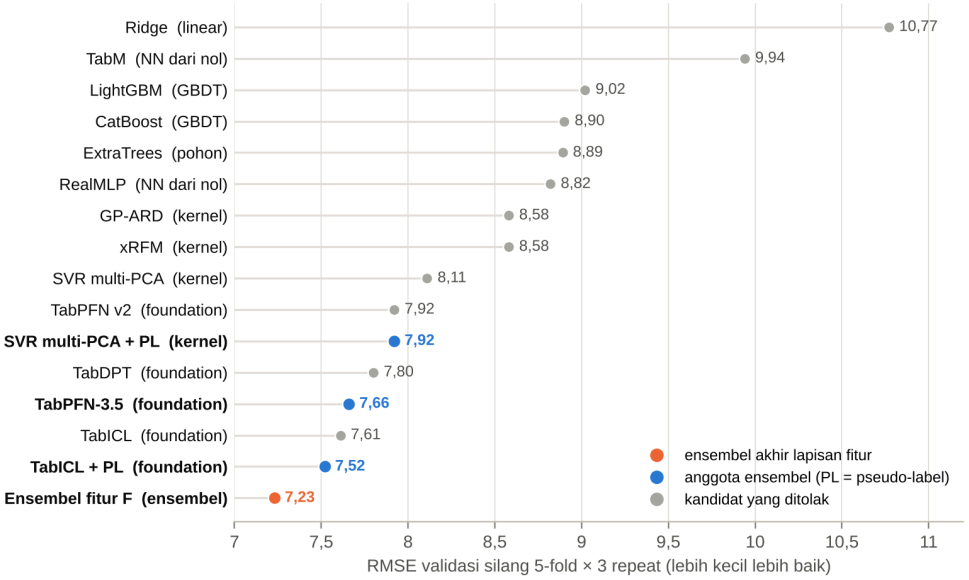




Seluruh komponen dilatih hanya pada partisi latih. Validasi 5-fold × 3 repeat. v9–v13: rata-rata RMSE per fold dengan seleksi bersarang; F: RMSE OOF gabungan.







BAB I
PENDAHULUAN

1.1 Latar Belakang

Indeks komposit berbasis indikator lingkungan dan iklim banyak dipakai untuk membandingkan wilayah, memantau kemajuan, dan menentukan prioritas kebijakan (OECD & JRC, 2008). Indeks semacam ini dibangun dari banyak indikator yang saling berkorelasi, dinormalisasi, lalu diagregasi menjadi satu skor. Ketika data seperti ini dibagikan untuk kompetisi atau kolaborasi riset, penyelenggara biasanya menyamarkan indikator agar entitas aslinya tidak dapat dikenali dan targetnya tidak dapat dicari dari sumber publik.

Data Science Competition FIK FAIR 2026 mengangkat kondisi tersebut. Peserta diminta memprediksi *Anonymous Competition Score*, yaitu target numerik dengan rentang 32,59–100,44 pada data latih, dari 24 fitur numerik anonim (`feature_01`–`feature_24`). Menurut panitia, fitur tersebut telah melalui *rank transformation*, *bounded transformation*, *private linear projection*, standardisasi, *controlled perturbation*, dan pembulatan. Akibatnya, fitur tidak lagi bermakna fisik, tidak bersatuan, dan tidak dapat dipetakan kembali ke indikator sumbernya. Kinerja diukur dengan *Root Mean Squared Error* (RMSE) pada 96 record uji, yang terbagi menjadi 29 record *public leaderboard* dan 67 record *private leaderboard*. Peringkat akhir hanya ditentukan oleh *private leaderboard*.

Secara formal, misalkan himpunan data latih adalah $D = \{(x_i, y_i)\}$ untuk $i = 1, \ldots, n$, dengan $n = 382$, $x_i \in \mathbb{R}^{24}$, dan $y_i \in \mathbb{R}$. Tujuannya adalah mempelajari fungsi $\hat{f}$ yang meminimalkan galat kuadrat pada $m = 96$ record uji:

$$\mathrm{RMSE}(\hat{f}) = \sqrt{\frac{1}{m}\sum_{j=1}^{m}\left(y_j - \hat{f}(\mathbf{x}_j)\right)^2} \tag{1}$$

Persoalan ini lebih sulit daripada regresi tabular biasa karena empat karakteristik data. Pertama, sampelnya sangat kecil (382 baris untuk 24 fitur), kondisi di mana GBDT yang biasanya unggul pada data tabular kehilangan keunggulannya (Grinsztajn et al., 2022). Kedua, fitur merupakan proyeksi yang sangat kolinear, sedangkan target bersifat bimodal dengan ekor berat. Ketiga, *public leaderboard* hanya berisi 29 record sehingga skornya berisik dan rawan *leaderboard overfitting* (Roelofs et al., 2019). Seleksi model karenanya harus bertumpu pada validasi silang yang dirancang cermat (Cawley & Talbot, 2010). Keempat, posisi baris pada berkas data ternyata hampir terurut menurut target (Spearman $\rho = -0{,}981$). Artefak konstruksi dataset seperti ini dapat membuat validasi terlalu optimistis jika tidak ditangani secara eksplisit (Kapoor & Narayanan, 2023; Kaufman et al., 2012), sehingga dibahas terbuka dan dimodelkan dengan seleksi bersarang.

Model *tabular foundation* seperti TabPFN (Hollmann et al., 2025) dan TabICL (Qu et al., 2025), yang dilatih awal untuk *in-context learning* pada data tabular kecil, menjadi kandidat yang relevan untuk kondisi tersebut.

1.2 Rumusan Masalah

Berdasarkan karakteristik data dan batasan evaluasi di atas, penelitian ini dipandu oleh lima pertanyaan penelitian (*research questions*, RQ) berikut.

Berdasarkan karakteristik data dan batasan evaluasi di atas, penelitian ini dipandu oleh lima pertanyaan penelitian (*research questions*, RQ) berikut.

- **RQ1 – Integritas data.** Karakteristik data apa yang harus ditangani agar estimasi kinerja valid dan bebas kebocoran?
- **RQ2 – Pemodelan pada data kecil.** Seberapa efektif *tabular foundation model* dengan *pseudo-labeling* dibandingkan baseline linear, GBDT, dan *neural network*?
- **RQ3 – Pemanfaatan urutan.** Bagaimana informasi posisi relatif digabungkan dengan prediksi fitur tanpa memakai label partisi validasi?
- **RQ4 – Galat dan ketahanan.** Di mana galat terkonsentrasi, dan seberapa stabil kinerja terhadap pembagian *public*/*private* serta record yang mirip?
- **RQ5 – Reproduktibilitas.** Bagaimana pipeline dikunci agar dapat diverifikasi panitia?

1.3 Tujuan

Penelitian ini bertujuan menjawab RQ1–RQ5 dengan membangun sistem prediksi yang akurat pada *private leaderboard*, memiliki estimasi kinerja yang jujur, dan dapat direproduksi penuh. Ada empat kontribusi utama: (1) audit forensik data yang memisahkan informasi sah dari artefak konstruksi dataset; (2) ensembel *tabular foundation model* dengan *pseudo-labeling* transduktif untuk data kecil; (3) koreksi *rank* berbasis tetangga fitur dengan model residual non-linear yang dipilih secara bersarang; dan (4) protokol evaluasi yang mencakup *bootstrap* berkelompok, simulasi *public*/*private*, dan *grouped stress test*.

Batasan. Karena fitur anonim, interpretasi hanya mungkin pada tingkat statistik. Komponen berbasis urutan mengasumsikan `test.csv` disusun dengan cara yang sama dengan `train.csv`; untuk data tanpa urutan bermakna tersedia mode cadangan berbasis fitur (RMSE sekitar 7,2). Seluruh desain dikembangkan pada 382 record yang sama tanpa himpunan uji lokal terpisah, sehingga sisa optimisme seleksi tidak sepenuhnya hilang. Penelitian ini tidak memakai data eksternal dan tidak melakukan *probing* terhadap *leaderboard*.

BAB II
PEMBAHASAN

2.1 Exploratory Data Analysis

EDA menghasilkan enam keputusan yang membentuk seluruh pipeline (Tabel 2.1). Tiga temuan paling menentukan: hubungan fitur–target bersifat non-linear, sinyal target tersimpan di komponen fitur bervarians kecil, dan urutan baris file membawa informasi peringkat target.

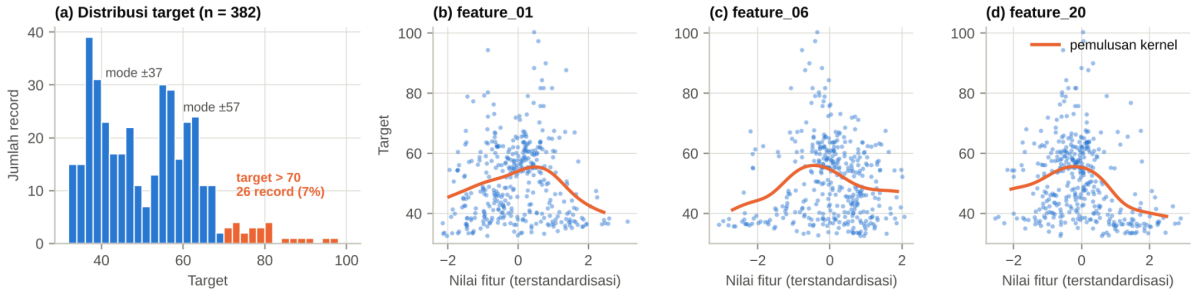
2.1.1 Kualitas dan Pembersihan Data

Data latih berisi 382 record dan data uji 96 record, masing-masing dengan 24 fitur numerik. Tidak ditemukan *missing value*, tidak ada duplikat vektor fitur di dalam data latih, dan tidak ada vektor fitur latih yang identik dengan data uji. `record_id` (D0001–D0478) tersusun acak dan tidak berkorelasi dengan target (Spearman $\rho = 0{,}048$), sehingga kolom ini tidak dipakai sebagai fitur.

Target berkisar 32,59–100,44 dengan rata-rata 51,20 dan simpangan baku 12,89. Nilai ekstrem **tidak dibuang** karena merupakan observasi sah dan justru menjadi penyumbang galat terbesar; menghapusnya membuat model tidak pernah belajar ekor distribusi. Penanganan *outlier* dilakukan di sisi model. *Clipping* fitur diuji dalam ablasi dan tidak memperbaiki RMSE (3,5176 vs 3,5169). Prediksi anggota SVR dibatasi ke rentang target latih karena tanpa batas ini SVR sempat mengekstrapolasi hingga 138 untuk record D0263.

Pasangan record terdekat berjarak 0,20 (jarak Euclidean terstandardisasi) dengan selisih target 2,74. Kedekatan ini bukan bukti duplikasi, sehingga tidak ada record yang dihapus. Risiko kebocoran melalui record yang mirip diuji terpisah dengan *grouped stress test* (Subbab 2.3).

2.1.2 Distribusi Target dan Hubungan Non-linear

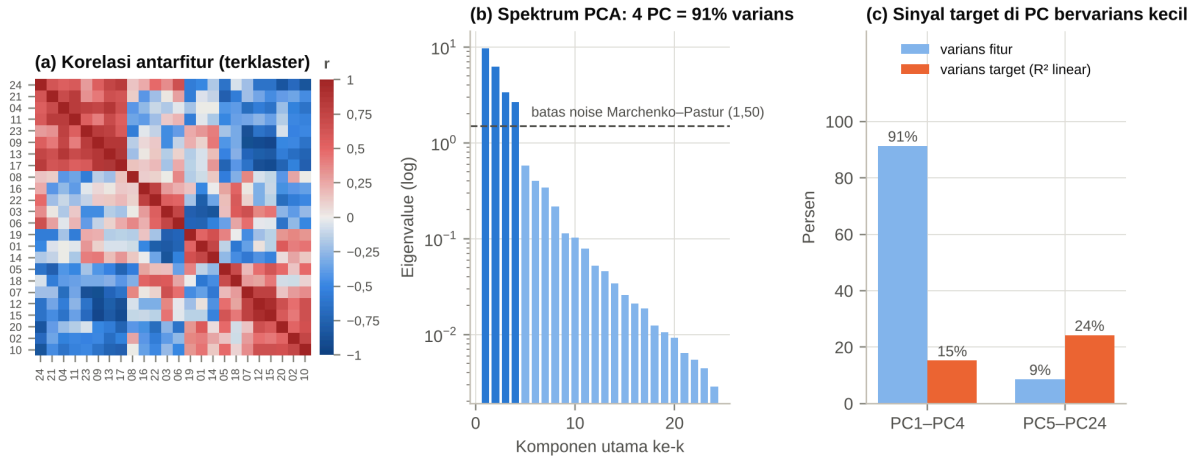


Gambar 2.1. (a) Distribusi target latih; batang oranye menandai 26 record bertarget > 70. (b)–(d) Contoh pola U-terbalik antara fitur dan target, dengan kurva pemulusan kernel.

Target bersifat bimodal dengan puncak di sekitar 37 dan 57 serta ekor kanan hingga 100 (*skewness* 0,75). Hanya 26 record (7%) yang bertarget di atas 70, tetapi kelompok ini menyumbang 40,9% SSE model berbasis fitur. Artinya, keberhasilan pada ekor lebih menentukan RMSE daripada keberhasilan pada mayoritas data.

Banyak fitur menunjukkan pola **U-terbalik**: target tertinggi muncul ketika fitur berada di sekitar pusat distribusinya dan menurun ke kedua arah. Pola ini konsisten dengan konsep "tipikalitas": record yang menjauh dari pusat ruang fitur cenderung bertarget rendah. Jarak Mahalanobis ke pusat data berkorelasi $\rho = -0{,}39$ dengan target, setara dengan fitur tunggal terbaik. Model linear (Ridge) hanya mencapai RMSE validasi silang 10,73, sedangkan model aditif berbasis *spline* mencapai 9,36. Model non-linear karenanya wajib digunakan.

2.1.3 Struktur Fitur: Kolinearitas dan Spektrum PCA

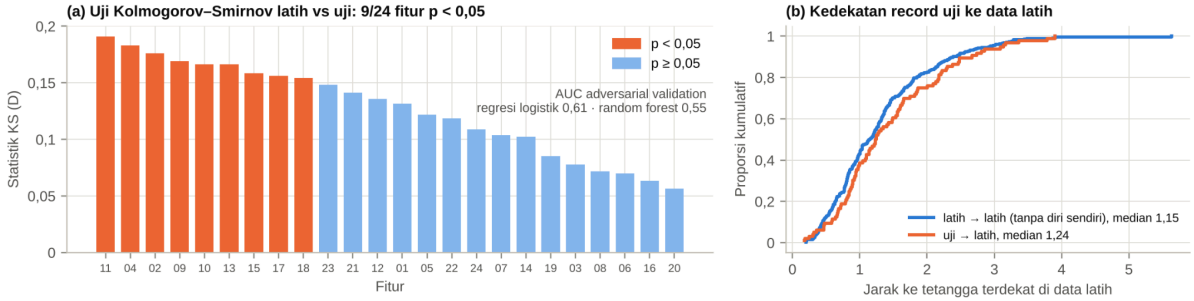


Gambar 2.2. (a) Matriks korelasi antarfitur yang diklaster (latih + uji). (b) Spektrum eigenvalue PCA dengan batas noise Marchenko–Pastur. (c) Perbandingan porsi varians fitur dengan porsi varians target yang dijelaskan secara linear oleh dua kelompok komponen utama.

Matriks korelasi memperlihatkan blok-blok fitur yang sangat kolinear: 44 pasang fitur memiliki $|r| > 0{,}7$ dengan nilai tertinggi 0,93. Hanya empat eigenvalue yang melampaui batas noise Marchenko–Pastur sebesar 1,50 (Marchenko & Pastur, 1967), dan keempat komponen tersebut menjelaskan 91% varians fitur. Pola ini konsisten dengan deskripsi panitia bahwa fitur adalah proyeksi linear dari indikator yang saling berkorelasi.

Temuan pentingnya ada pada Gambar 2.2(c). PC1–PC4 menguasai 91% varians fitur, tetapi hanya menjelaskan 15% varians target secara linear. Sebaliknya, PC5–PC24 yang hanya memuat 9% varians fitur menjelaskan 24% varians target. Reduksi dimensi agresif dengan demikian membuang sinyal: SVR pada empat komponen menghasilkan RMSE di atas 10. Keputusan yang diambil: model *tabular foundation* dan model pohon memakai 24 fitur mentah, sedangkan SVR memakai rata-rata prediksi dari beberapa dimensi PCA (10, 12, 14, 16, dan 20 komponen) agar tidak bergantung pada satu pilihan dimensi. Upaya membalik proyeksi dengan ICA juga diuji, tetapi gagal karena sumber yang dipulihkan berekor tebal (kurtosis 4–9) dan tidak menyerupai indikator ber-*rank* yang dibatasi.

2.1.4 Pergeseran Distribusi Latih–Uji

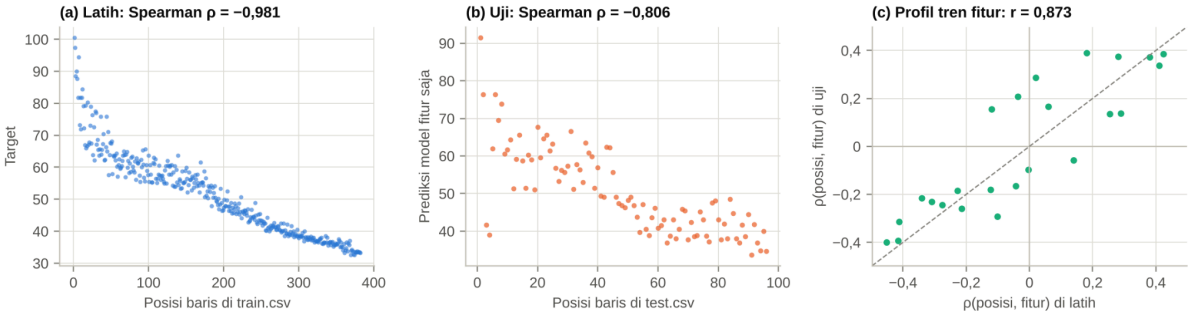


Gambar 2.3. (a) Statistik Kolmogorov–Smirnov per fitur antara data latih dan uji, diurutkan dari terbesar. (b) Distribusi kumulatif jarak ke tetangga terdekat di data latih untuk record latih dan record uji.

Uji Kolmogorov–Smirnov menunjukkan 9 dari 24 fitur berbeda signifikan ($p < 0,05$), tetapi besarnya pergeseran kecil (D maksimum 0,19). *Adversarial validation* menguatkan kesimpulan ini: pengklasifikasi yang dilatih membedakan record latih dari record uji hanya mencapai AUC 0,61 (regresi logistik) dan 0,55 (*random forest*), dekat dengan tebakan acak 0,50. Record uji juga sama dekatnya ke data latih seperti record latih ke sesamanya (median jarak tetangga terdekat 1,24 vs 1,15; uji KS $p = 0,28$).

Karena record uji berada di wilayah ruang fitur yang sama dengan data latih, *random K-fold* merupakan simulasi yang representatif untuk skenario uji. Pembobotan ulang sampel (*importance reweighting*) tidak diperlukan. Skema validasi utama ditetapkan 5-fold × 3 *repeat* dengan partisi identik untuk semua kandidat model.

2.1.5 Audit Urutan Penyimpanan



Gambar 2.4. (a) Target terhadap posisi baris pada train.csv. (b) Prediksi model berbasis fitur (tanpa informasi posisi) terhadap posisi baris pada test.csv. (c) Korelasi posisi–fitur pada data latih dibandingkan dengan data uji untuk 24 fitur.

Audit forensik membedakan dua hal yang sering tertukar. Nomor `record_id` tidak informatif, tetapi **posisi baris di dalam file** sangat informatif: target pada `train.csv` hampir terurut menurun (Spearman $\rho = -0{,}981$). Label uji tidak tersedia, sehingga urutan `test.csv` diperiksa secara tidak langsung melalui dua bukti tanpa label. Pertama, prediksi model yang hanya memakai 24 fitur ikut menurun sepanjang file uji ($\rho = -0{,}806$). Kedua, pola korelasi antara posisi dan setiap fitur pada data uji mengikuti pola yang sama pada data latih ($r = 0{,}873$). Kedua bukti mengindikasikan bahwa kedua file disusun dengan cara yang sama, yaitu diurutkan menurut target atau besaran yang sangat dekat dengan target.

Posisi baris karenanya membawa informasi tentang **peringkat relatif** target, bukan nilai target itu sendiri. Ada tiga implikasi untuk pemodelan.

1. Posisi global tidak boleh dipakai langsung dalam validasi silang. Posisi tersebut dihitung dari pengurutan seluruh data, sehingga ikut membawa informasi dari partisi validasi. Posisi harus dinormalisasi ulang secara terpisah di dalam setiap partisi.
2. Posisi saja tidak cukup. Model isotonik berbasis posisi saja mencapai RMSE median 3,97 (persentil 5–95: 2,90–5,53) pada 200 simulasi partisi dengan normalisasi terpisah. Galat terbesar terjadi pada baris awal bertarget tinggi, tempat kurva target paling curam.
3. Fitur diperlukan untuk memperbaiki estimasi posisi tiap record uji terhadap data latih. Dari pemikiran inilah lahir komponen koreksi *rank* berbasis tetangga fitur (Subbab 2.2).

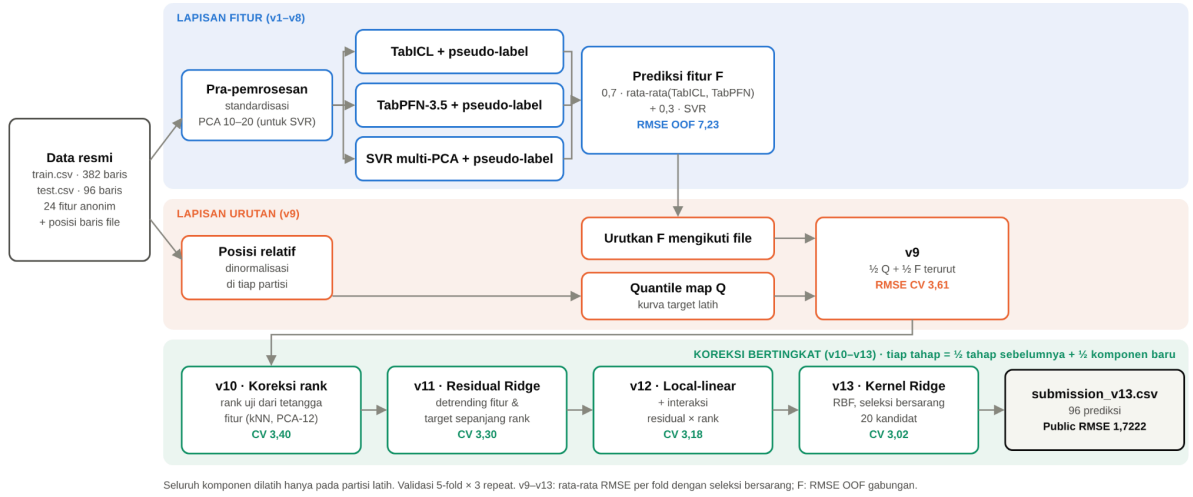
Tabel 2.1. Ringkasan temuan EDA dan keputusan pemodelan

Temuan	**Bukti kuantitatif**	**Keputusan**
Data bersih; record_id acak	0 missing, 0 duplikat; ρ(ID, target) = 0,048	Tanpa imputasi; record_id tidak dipakai sebagai fitur
Target bimodal dengan ekor berat	7% record bertarget > 70 menyumbang 40,9% SSE	Target asli dipertahankan; prediksi SVR dibatasi ke rentang latih; galat dianalisis per subkelompok
Hubungan fitur–target U-terbalik	Ridge 10,73 vs spline aditif 9,36	Model non-linear: tabular foundation model dan SVR-RBF
Sinyal target di PC bervarians kecil	PC5–PC24 (9% varians fitur) menjelaskan 24% varians target	Tanpa reduksi dimensi agresif; SVR dirata-ratakan atas beberapa dimensi PCA

Pergeseran latih–uji ringan	KS 9/24 fitur; AUC adversarial 0,55–0,61; jarak tetangga setara	*Random 5-fold × 3 repeat; tanpa pembobotan ulang*
Urutan file membawa peringkat target	ρ = −0,981 (latih), −0,806 (uji, tanpa label)	Posisi dinormalisasi per partisi; rank uji diestimasi dari tetangga fitur; seleksi bersarang

2.2 Machine Learning Deployment

Pipeline akhir tersusun atas tiga lapisan (Gambar 2.5). Lapisan fitur menghasilkan prediksi F dari 24 fitur. Lapisan urutan memetakan F ke kurva target latih berdasarkan posisi relatif. Empat tahap koreksi kemudian memperbaiki galat yang tersisa. Setiap lapisan dibangun dan diterima hanya jika lolos protokol validasi yang sama.



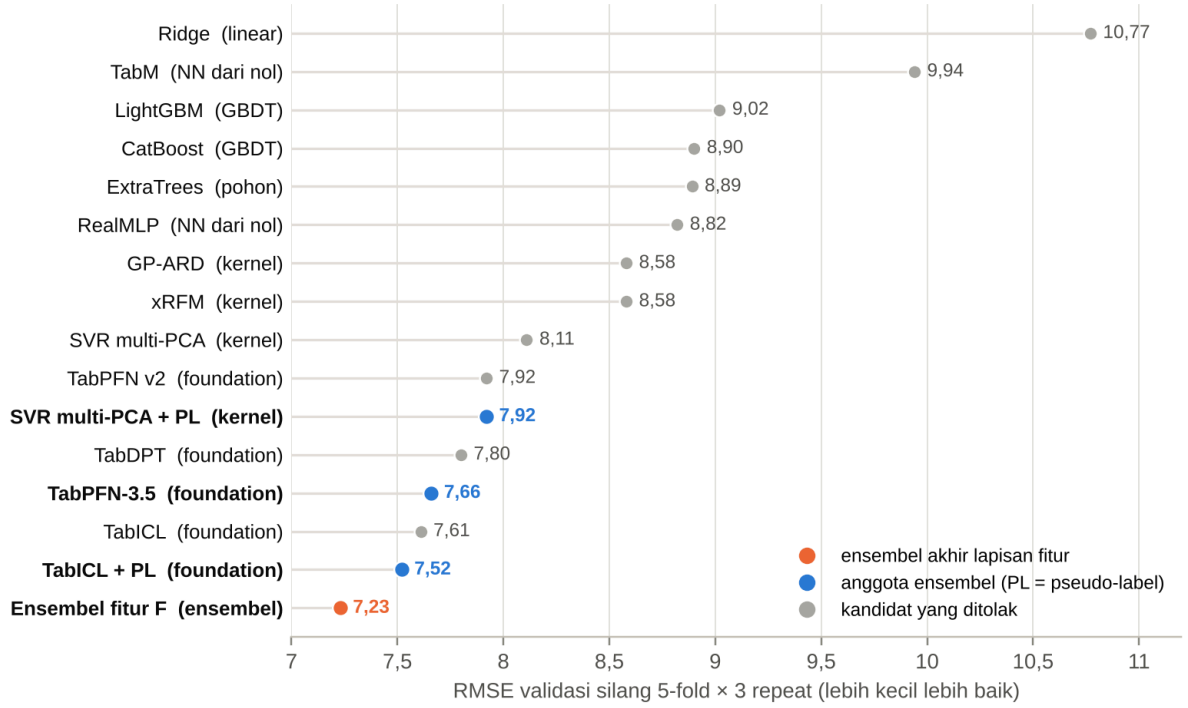
Gambar 2.5. Alur kerja pipeline prediksi, dari data resmi hingga berkas submission. Angka di setiap kotak adalah RMSE validasi silang tahap tersebut.

2.2.1 Protokol Validasi dan Aturan Adopsi

Seluruh kandidat dievaluasi pada 15 partisi yang identik, yaitu 5-fold × 3 *repeat* dengan *seed* 42. Kandidat yang berbeda dengan demikian dibandingkan pada record validasi yang sama. Setiap pemilihan konfigurasi dilakukan secara **bersarang**: untuk setiap *outer fold*, *inner* 5-fold pada baris latih *outer* memilih konfigurasi, lalu konfigurasi terpilih dievaluasi pada baris validasi *outer* yang tidak pernah dilihatnya. Prosedur ini mencegah bias seleksi yang membuat estimasi kinerja terlalu optimistis (Cawley & Talbot, 2010).

Kandidat baru hanya menggantikan model berjalan jika memenuhi dua syarat sekaligus. Pertama, RMSE bersarangnya turun lebih dari 0,01. Kedua, *bootstrap* berpasangan memberi frekuensi perbaikan di atas 0,9. *Bootstrap* dilakukan per `record_id` sehingga ketiga prediksi *repeat* untuk satu record selalu diambil bersama. Skor *public leaderboard* hanya dipakai untuk memeriksa validitas berkas, tidak pernah untuk memilih model atau bobot.

2.2.2 Lapisan Fitur



Gambar 2.6. RMSE validasi silang setiap kandidat model berbasis fitur. Sebagai pembanding, prediksi konstan (rata-rata target) menghasilkan RMSE 12,89. TabPFN-3.5 ditampilkan tanpa pseudo-label; di dalam ensembel model ini dipakai dengan pseudo-label.

Lima belas kandidat dari enam keluarga model diuji (Gambar 2.6). Model *tabular foundation* unggul jelas atas GBDT dan *neural network* yang dilatih dari nol. Model ini membawa *prior* hasil pelatihan awal pada jutaan dataset sintetis dan memprediksi melalui *in-context learning*, sehingga tidak perlu mempelajari *prior* dari 382 baris saja (Hollmann et al., 2025; Qu et al., 2025). *Fine-tuning* TabICL justru memperburuk RMSE (7,60 menjadi 7,69), yang menegaskan bahwa *prior* bawaan lebih baik daripada yang dapat dipelajari dari data sekecil ini. TabICL karenanya dipakai *zero-shot*, dengan normalisasi internal dimatikan dan prediksi dirata-ratakan atas empat *seed*.

Peningkatan terbesar pada lapisan ini datang dari ***pseudo-labeling* transduktif**. Record kueri (fold validasi saat CV, atau 96 record uji saat inferensi) diprediksi sekali, dibagi menjadi beberapa bagian, lalu setiap bagian diprediksi ulang dengan bagian lain dan *pseudo-label*-nya ditambahkan ke konteks. Ada tiga pengaman. Label asli record kueri tidak pernah dipakai. Sebuah record tidak pernah melihat *pseudo-label*-nya sendiri. Rasio baris *pseudo* terhadap baris berlabel juga dijaga sama antara CV dan uji (0,19). Teknik ini menurunkan RMSE TabICL dari 7,61 menjadi 7,52 dan membaik di 12 dari 15 fold. Mekanismenya terverifikasi: reduksi galat kuadrat terbesar (3,35) terjadi pada record yang berjarak 1,2–1,8 dari tetangga latih terdekat, sedangkan record yang memiliki tetangga dekat hampir tidak berubah (0,02). *Pseudo-label* bekerja sebagai tetangga tambahan di wilayah ruang fitur yang jarang.

SVR menjadi anggota pelengkap karena galatnya paling berbeda dari model *foundation* (korelasi residual 0,84–0,86, dibanding 0,96–0,98 antarmodel *foundation*). SVR dilatih pada target log yang distandardisasi, dirata-ratakan atas lima dimensi PCA dan empat konfigurasi regularisasi (C ∈ {10, 30}, skala ∈ {0,7; 1,0}), lalu juga diberi *pseudo-label*. Bobot NNLS bebas antara dua model *foundation* terbukti tidak stabil karena keduanya hampir kolinear (RMSE bersarang 7,358 vs 7,316). Karena itu bobot dikunci menjadi F = 0,7 · rata-rata(TabICL, TabPFN-3.5) + 0,3 · SVR, dengan RMSE OOF 7,23.

Lapisan ini sudah mendekati batas informasi fitur. Tiga model *foundation* dengan *prior* berbeda gagal pada record yang sama, dan tiga *learner* yang dilatih pada residual F tidak mencapai R^2 validasi silang positif. Penurunan RMSE lebih lanjut harus datang dari sumber informasi lain, yaitu urutan file.

2.2.3 Lapisan Urutan dan Koreksi Bertingkat

Misalkan u ∈ (0, 1) adalah posisi relatif sebuah record di dalam file partisinya, dihitung sebagai (indeks + 0,5)/n secara terpisah untuk partisi latih dan partisi kueri. **Quantile map** Q(u) adalah regresi isotonik menurun dari target latih terhadap posisi relatifnya, yang dievaluasi pada posisi relatif record kueri. Prediksi v9 adalah rata-rata Q dengan prediksi fitur F yang diurutkan menurun mengikuti urutan file kueri. Aturan ini dipilih dari tujuh aturan kombinasi yang ditetapkan sebelum evaluasi, tanpa bobot yang dipelajari dari fold yang sedang dinilai.

$$\hat{y}_j^{(\mathrm{v9})} = \frac{1}{2} Q(u_j) + \frac{1}{2} F_{(j)}, \qquad F_{(1)} \geq F_{(2)} \geq \ldots \geq F_{(m)} \tag{2}$$

Kelemahan v9 adalah asumsi bahwa persentil ke-p pada file kueri tepat bersesuaian dengan persentil ke-p pada data latih. Pada sampel kecil asumsi ini meleset, terutama di bagian awal file yang kurva targetnya curam. Empat tahap berikutnya memperbaiki kelemahan tersebut secara bertahap. Setiap tahap mencampur 50% prediksi tahap sebelumnya dengan 50% komponen baru. Bobot tetap ini berfungsi sebagai penyusutan (*shrinkage*) dan tidak pernah dipelajari dari label validasi.

1. **v10 – Koreksi *rank* berbasis tetangga fitur.** Setiap record kueri dicarikan *k* tetangga terdekat di data latih pada ruang PCA-12 yang di-*whitening*. *Rank*-nya diestimasi sebagai rata-rata *rank* tetangga dengan bobot invers kuadrat jarak, lalu dikalibrasi dengan tren *leave-one-out* untuk mengoreksi tarikan ke tengah distribusi. Estimasi tersebut kemudian dihaluskan sepanjang urutan kueri, dibuat monoton, dan dipetakan ke kurva target latih.
2. **v11 – Residual Ridge.** Tren posisi dihilangkan dari fitur dan target latih. Model Ridge kemudian memprediksi deviasi target kueri dari kurva target berdasarkan residual fiturnya.

3. **v12 – Pemulusan *local-linear* dan interaksi.** Pemulus Gaussian diganti pemulus *local-linear* untuk mengurangi bias di batas file. Interaksi residual fitur × *rank* terpusat ditambahkan sehingga pengaruh fitur boleh berbeda di bagian awal dan akhir kurva.
4. **v13 – *Kernel Ridge Regression* RBF.** Model linear pada tahap sebelumnya diganti model non-linear dengan 48 masukan (24 residual dan 24 interaksi). *Inner* CV memilih satu dari 20 kandidat konfigurasi; pada data latih penuh terpilih $\alpha = 0{,}1$ dan $\gamma = 2/48$.

Tabel 2.2. Kontribusi setiap tahap (RMSE bersarang, rata-rata 15 fold)

Tahap	Komponen baru	RMSE CV	Δ RMSE	Fold membaik	Interval bootstrap 95% Δ
v9	Quantile map + F terurut	3,613	–	–	–
v10	Koreksi rank kNN	3,401	−0,212	11/15	[−0,356; −0,092]
v11	Residual Ridge	3,303	−0,098	12/15	[−0,182; −0,023]
v12	*Local-linear* + *interaksi*	3,179	−0,124	14/15	[−0,187; −0,054]
v13	*Kernel Ridge RBF*	3,016	−0,163	15/15	[−0,237; −0,073]

Setiap tahap memberi perbaikan yang interval *bootstrap*-nya tidak memuat nol, dan v13 membaik di seluruh 15 fold dan ketiga *repeat*. Secara kumulatif, koreksi bertingkat menurunkan RMSE sebesar 16,5% dari v9.

2.2.4 Kesiapan Implementasi dan Reproduktibilitas

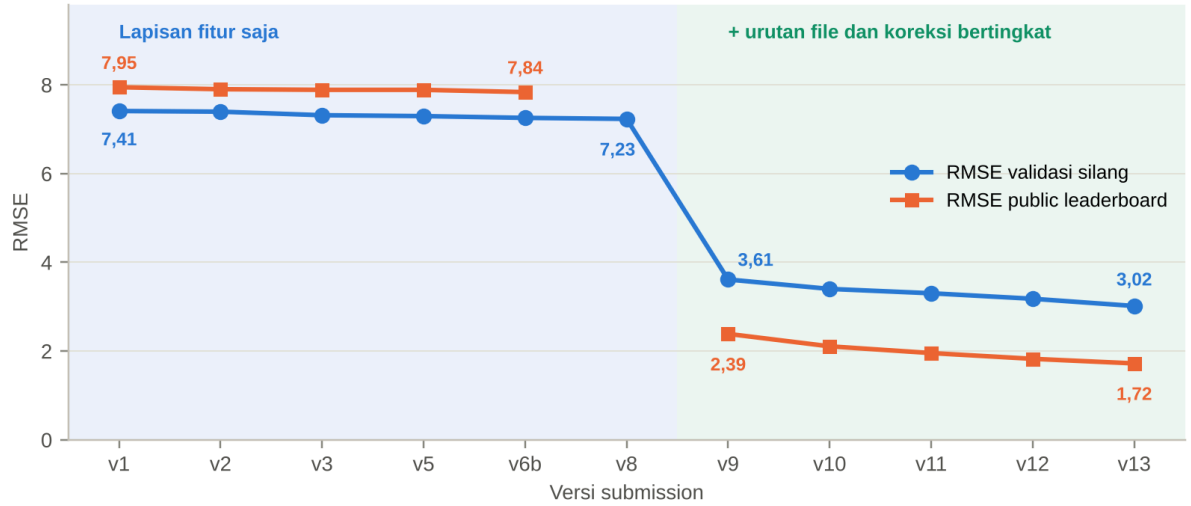
Tahap v13 berjalan sepenuhnya di CPU dengan Python 3.12, NumPy 2.5.3, pandas 3.0.6, SciPy 1.18.1, dan scikit-learn 1.9.1. Lapisan fitur membutuhkan GPU (Kaggle T4 × 2) untuk model *foundation*. Setiap rilis menyertakan berkas *manifest* yang mencatat *hash* SHA-256 semua masukan dan keluaran, versi pustaka, *seed* seleksi (6099), dan konfigurasi terpilih. Ekspor dijalankan dua kali dan menghasilkan CSV yang identik per *byte*. Notebook juga memuat asersi otomatis: 96 `record_id` unik sesuai templat, seluruh prediksi *finite*, dan prediksi notebook cocok dengan audit terpisah hingga toleransi 10^{-10}.

Untuk data baru, pipeline dapat dijalankan dalam dua mode. Mode penuh memakai urutan file dan menghasilkan akurasi terbaik selama data disusun dengan cara yang sama. Mode cadangan hanya memakai lapisan fitur (RMSE sekitar 7,2) untuk data yang tidak memiliki urutan bermakna. Pemisahan ini membuat solusi tetap dapat dipakai ketika asumsi tentang urutan file tidak terpenuhi.

2.3 Hasil Prediksi

Pipeline final v13 mencapai RMSE validasi silang 3,016 (MAE OOF 2,15) dan RMSE *public leaderboard* 1,7222. Dibanding submission berbasis fitur terbaik (*public* 7,837), galat *public* turun 78%. Sisa galat terkonsentrasi pada 10% record awal file yang bertarget tinggi.

2.3.1 Kinerja dan Evolusi Model

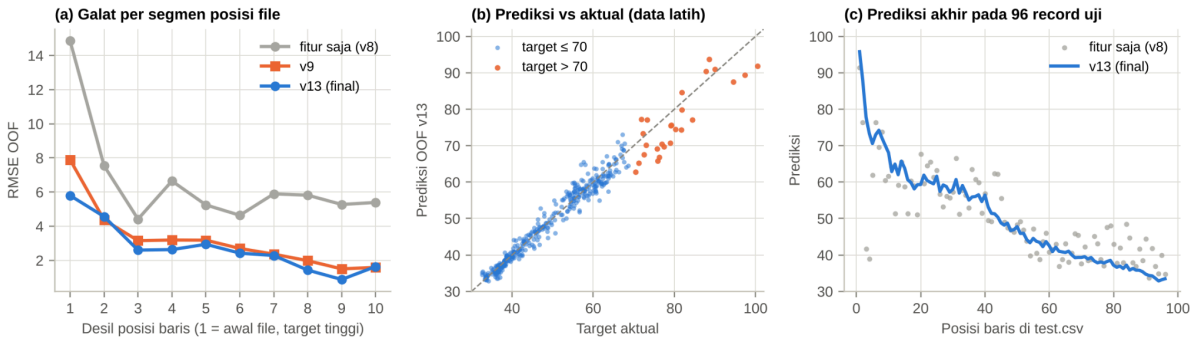


Gambar 2.7. RMSE validasi silang dan RMSE public leaderboard untuk setiap versi submission. Skor public v8 tidak tersedia. CV v1–v8 dihitung dari OOF gabungan, sedangkan v9–v13 adalah rata-rata RMSE per fold.

Evolusi model terbagi dalam dua fase (Gambar 2.7). Pada fase fitur, CV dan skor *public* bergerak dalam langkah kecil (CV 7,41 menjadi 7,23; *public* 7,95 menjadi 7,84). Perubahan sekecil ini berada di dalam rentang noise 29 record *public* (4,7–9,9), sehingga seleksi tetap bertumpu pada CV. Pada fase urutan, kelima versi v9–v13 memiliki peringkat yang sama persis menurut CV dan menurut skor *public*. Setiap perbaikan CV selalu diikuti perbaikan *public*, sehingga CV terbukti menjadi alat seleksi yang dapat dipercaya.

Skor *public* yang lebih rendah dari CV tidak boleh dibaca sebagai prakiraan skor *private*. Simulasi pembagian 29/67 menunjukkan bahwa selisih rata-rata antara RMSE *public* dan *private* untuk model yang sama adalah sekitar 0,75, dengan persentil ke-95 RMSE *private* sekitar 4,6.

2.3.2 Analisis Galat



Gambar 2.8. (a) RMSE out-of-fold per desil posisi baris untuk model fitur saja, v9, dan v13. (b) Prediksi OOF v13 terhadap target aktual. (c) Prediksi akhir v13 pada test.csv dibandingkan prediksi fitur saja.

Gambar 2.8(a) menunjukkan di mana perbaikan terjadi. Model fitur saja memiliki RMSE 14,85 pada desil pertama file dan 4,4–7,5 di desil lainnya. Pada v13, RMSE desil pertama turun menjadi 5,80 dan desil lainnya menjadi 0,9–4,6. Meski demikian, 38 record pertama masih menyumbang 34,5% SSE (RMSE 5,71 dibanding 2,61 untuk sisanya), dengan bias +1,48 (prediksi terlalu rendah). Pola serupa tampak menurut nilai target: 26 record bertarget di atas 70 memiliki RMSE 7,08 dan bias +3,89, sedangkan record bertarget di bawah 45 hanya 1,54.

Model tetap terkalibrasi dengan baik di sebagian besar rentang. Pada sembilan dari sepuluh desil prediksi, selisih rata-rata target dan rata-rata prediksi tidak lebih dari 0,44. Hanya desil teratas yang selisihnya 1,35. Sepuluh record dengan galat terbesar (misalnya D0414, D0203, D0419) menyumbang 23,6% SSE dengan galat ke dua arah. Karena itu koreksi global seperti menaikkan semua prediksi tinggi tidak dapat dibenarkan.

Pada data uji (Gambar 2.8c), prediksi v13 berkisar 32,86–95,79 dengan rata-rata 50,27, mendekati distribusi target latih (32,59–100,44; rata-rata 51,20). Prediksi mengikuti urutan file, tetapi tetap memuat deviasi lokal dari fitur. Dibanding prediksi fitur saja yang tersebar lebar, v13 mampu menjangkau record ekstrem di awal file yang sebelumnya tidak terjangkau.

2.3.3 Uji Ketahanan

Tabel 2.3. Uji ketahanan komponen koreksi v13 dibanding komponen residual sebelumnya

Uji	**Ukuran**	**Komponen lama**	**Komponen v13**
Grouped stress test, ambang jarak 0,35 (374 grup)	RMSE	3,375	3,021
Grouped stress test, ambang jarak 0,70 (322 grup, grup terbesar 22 record)	RMSE	3,536	3,223
Kurva belajar: 143 / 214 / 286 baris latih	RMSE	3,98 / 3,63 / 3,44	3,73 / 3,34 / 3,12
Simulasi public 29 / private 67 (50 kueri × 50 partisi)	Rata-rata RMSE kueri	3,485	3,2
	Persentil 95 RMSE private	4,779	4,602
	Rata-rata |public − private|	0,827	0,752

BAB III
PENUTUP

3.1 Kesimpulan dan Saran

Kesimpulan. Penelitian ini membangun pipeline prediksi *Anonymous Competition Score* yang mencapai RMSE validasi silang bersarang 3,016 dan RMSE *public leaderboard* 1,7222. Jawaban atas kelima pertanyaan penelitian adalah sebagai berikut.

1. **RQ1 – Integritas data.** Data bersih dari *missing value* dan duplikat. Ada tiga risiko yang harus ditangani. Pertama, fitur sangat kolinear, tetapi sinyal target berada di komponen bervarians kecil, sehingga reduksi dimensi agresif harus dihindari. Kedua, pergeseran latih–uji ringan (AUC *adversarial* 0,55–0,61), sehingga *random* K-fold representatif. Ketiga, urutan baris membawa peringkat target ($\rho = -0{,}981$), sehingga posisi harus dinormalisasi per partisi dan setiap pemilihan konfigurasi dilakukan secara bersarang.
2. **RQ2 – Pemodelan pada data kecil.** Model *tabular foundation* mengungguli GBDT, *neural network* dari nol, dan model linear (TabICL 7,61 vs CatBoost 8,90 vs Ridge 10,77). *Pseudo-labeling* transduktif menurunkan RMSE menjadi 7,52, dan ensembel dengan SVR mencapai 7,23. Residual ensembel tidak dapat dipelajari lagi, yang menunjukkan bahwa informasi dari 24 fitur hampir habis termanfaatkan.
3. **RQ3 – Pemanfaatan urutan.** Menggabungkan posisi relatif dengan prediksi fitur menurunkan RMSE CV dari 7,23 menjadi 3,61 (v9). Empat tahap koreksi bertingkat menurunkannya lagi menjadi 3,02. Setiap tahap memiliki interval *bootstrap* yang tidak memuat nol, dan peringkat v9–v13 menurut CV identik dengan peringkat menurut skor *public*.
4. **RQ4 – Konsentrasi galat dan ketahanan.** Galat terkonsentrasi pada 10% record awal file yang bertarget tinggi (34,5% SSE). Record bertarget di atas 70 masih cenderung diprediksi terlalu rendah (bias +3,89). Perbaikan bertahan pada *grouped stress test*, dan kurva belajar menunjukkan galat masih turun seiring bertambahnya data.
5. **RQ5 – Reproduktibilitas.** Pipeline terkunci melalui *manifest* SHA-256, *seed* tetap, dan asersi otomatis, serta menghasilkan berkas identik per *byte* saat dijalankan ulang. Tersedia pula mode cadangan berbasis fitur untuk data tanpa urutan bermakna.

Saran. Saran dikelompokkan menurut pihak yang dapat menindaklanjutinya.

1. **Untuk penyusun dataset kompetisi.** Acak urutan baris sebelum data dirilis, lalu periksa korelasi posisi–target sebagai bagian dari *quality control*. Pemeriksaan sederhana ini mencegah artefak penyimpanan mengambil alih tugas prediksi. Porsi *public leaderboard* juga sebaiknya diperbesar agar umpan balik peserta tidak didominasi noise.

2. **Untuk penggunaan model.** Jalankan tiga pemeriksaan sebelum setiap inferensi. Pertama, jika korelasi antara prediksi fitur dan posisi file lebih lemah dari −0,5, gunakan mode cadangan berbasis fitur. Kedua, jika AUC *adversarial validation* antara data baru dan data latih melebihi 0,65, model perlu dilatih ulang. Ketiga, jika selisih rata-rata target dan prediksi pada salah satu desil prediksi melebihi 2 poin setelah label baru tersedia, lakukan kalibrasi ulang. Prediksi di atas 70 sebaiknya disertai interval ketidakpastian dan ditinjau manual, karena di wilayah inilah galat terbesar terjadi.
3. **Untuk penelitian lanjutan.** Prioritasnya adalah ekor target: model dengan varians galat heterogen atau regresi kuantil dapat mengurangi bias pada record bertarget tinggi. Kurva belajar menunjukkan bahwa penambahan data berlabel yang sah masih akan menurunkan galat. Terakhir, evaluasi pada himpunan uji yang benar-benar terpisah diperlukan untuk menghapus sisa optimisme akibat seleksi riset pada data yang sama.

DAFTAR PUSTAKA

Cawley, G. C., & Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research, 11*, 2079–2107.

Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? In *Advances in Neural Information Processing Systems 35* (Datasets and Benchmarks Track).

Hollmann, N., Müller, S., Purucker, L., Krishnakumar, A., Körfer, M., Hoo, S. B., Schirrmeister, R. T., & Hutter, F. (2025). Accurate predictions on small data with a tabular foundation model. *Nature, 637*, 319–326.

Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns, 4*(9), Article 100804.

Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data, 6*(4), 1–21.

Marchenko, V. A., & Pastur, L. A. (1967). Distribution of eigenvalues for some sets of random matrices. *Mathematics of the USSR-Sbornik, 1*(4), 457–483.

OECD & JRC. (2008). *Handbook on constructing composite indicators: Methodology and user guide*. OECD Publishing.

Qu, J., Holzmüller, D., Varoquaux, G., & Le Morvan, M. (2025). TabICL: A tabular foundation model for in-context learning on large data. In *Proceedings of the 42nd International Conference on Machine Learning*.

Roelofs, R., Shankar, V., Recht, B., Fridovich-Keil, S., Hardt, M., Miller, J., & Schmidt, L. (2019). A meta-analysis of overfitting in machine learning. In *Advances in Neural Information Processing Systems 32*.